

CHARGESHIELD

Sanal POS İşyerleri İçin Açıklanabilir Erken Risk Uyarı Sistemi

Literatür İncelemesi • Veri Araştırması • Teknoloji İncelemesi

**Samsung AI & Marketing Innovation Campus
Capstone - İlk Araştırma Teslimi**

Sabit Problem Tanımı

Bankanın sanal POS verdiği işyerlerini merchant $\times$ gün seviyesinde izleyerek; işlem, settlement/payout, iade, dispute/chargeback, recovery ve müşteri şikâyeti sinyallerinden önümüzdeki 30 gün içinde ciddi merchant riski veya tahsil edilemeyen finansal zarar oluşma olasılığını, zarar tamamen gerçekleşmeden önce tahmin etmek.

Not: “Hizmet vermeme + müşteriye oyalama” bu sistemin ilk ve en anlaşılır risk senaryosudur; projenin tamamı değildir.

00 / YÖNETİCİ ÖZETİ Projenin Konumu ve İş Değeri

ChargeShield, tekil kart işleminin sahte olup olmadığını sınıflandıran klasik bir fraud modeli değildir. Sistem, bankanın B2B müşterisi olan sanal POS işyerinin zaman içindeki davranışının bozulup bozulmadığını ve bu bozulmanın gelecekte bankada tahsil edilemeyen bir exposure yaratıp yaratmayacağını tahmin etmeye odaklanır.

Ana gözlem birimi: merchant × day. **Ana tahmin ufku:** 30 gün. **Ana ekonomik hedef:** net_unrecoverable_loss_30d. Şikâyet NLP'si ana karar verici değil, ana modele eklenen erken sinyal modülüdür.

Bileşen	ChargeShield karşılığı
Hedef kullanıcı	Bankanın acquiring / merchant risk / fraud / chargeback / uyum ekipleri
B2B müşteri	Sanal POS işyeri; kart hamili dolaylı güven paydaşıdır
Ana karar	Hangi merchant bugün analist incelemesine öncelikli girmeli?
Ana KPI	PR-AUC, Precision@K, Recall@AlertBudget, Detection Lead Time, Potentially Preventable Loss
Müşteri KPI	Yanlış-pozitif merchant oranı ve sağlıklı merchant retention
Aksiyon	Otomatik POS kapatma değil; açıklanabilir inceleme, settlement/reserve/policy review önerisi

Problem kapsamı

- Senaryo 1 - Hizmet sunamama / iade krizi: müşteri şikâyeti ve refund talepleri yükselir; chargeback daha sonra gelir.
- Senaryo 2 - Finansal kötüleşme: merchant likiditesi bozulur; payout davranışı, bakiye ve recovery kapasitesi zayıflar.
- Senaryo 3 - Bust-out / sahte işlem / transaction laundering / card testing gibi merchant-kaynaklı kötüye kullanım örüntüleri.
- Ortak ekonomik sonuç: dispute/chargeback veya başka yükümlülük oluşur ve merchant, reserve, held settlement veya teminat üzerinden yeterli recovery yapılamaz.

AI in Marketing bağlantısı

Proje saf bir kampanya optimizasyonu değildir. Pazarlama bağlamı, bankanın B2B merchant portföyünü riskle düzeltilmiş biçimde yönetmesi; sağlıklı merchant ilişkilerini korurken gereksiz kısıtları ve müşteri güven kaybını azaltmasıdır. SDG hizalaması ikincildir ve bu teslimde ana değerlendirme eksenidir.

BÖLÜM I Literatür İncelemesi

1. Giriş ve araştırma soruları

Bu projenin temel araştırma sorusu şudur: **Merchant düzeyindeki işlem, settlement/recovery ve müşteri-şikâyeti sinyalleri, önümüzdeki 30 gün içindeki ciddi merchant riskini ve tahsil edilemeyen acquirer zararını yeterince erken tahmin edebilir mi?**

Bu soru üç alt soruya ayrılır: (i) merchant'ın kendi geçmişine göre sapma özellikleri ham seviyelerden daha fazla sinyal taşır mı, (ii) müşteri şikâyeti/NLP sinyali banka-içi modele ek ölçülebilir değer sağlar mı, (iii) model sınırlı analist kapasitesi altında ekonomik olarak faydalı bir alarm sıralaması üretir mi?

2. Literatürün tematik organizasyonu

Tema	Literatürden çıkan ana fikir	Projeye etkisi
Merchant monitoring & acquiring risk	Risk yalnız işlem seviyesinde değil merchant varlığı ve yaşam döngüsünde de izlenir.	Gözlem birimi merchant × day; analist kuyruğu.
Temporal fraud & delayed labels	Davranış zamanla değişir; geçmiş pencereler ve etiket gecikmesi önemlidir.	1/7/30 günlük rolling özellikler; temporal split; leakage kontrolü.
Customer voice / business deterioration	Geri bildirimin seviyesi kadar zaman içindeki bozulma hızı da sinyal taşır.	Complaint velocity ve risk konu oranları yardımcı feature olur.
eWOM, trust & relationship management	Olumsuz tüketici içeriği güven ve davranışsal niyetle ilişkilidir.	Finansal ground truth değil; B2B ilişki ve güven gerekçesini destekler.

3. Merchant monitoring ve sektör doğrulaması

Mastercard Merchant Monitoring, merchant'ları yalnız tekil işlemler üzerinden değil bütünsel biçimde değerlendirir; acquirer, PSP ve payment facilitator kuruluşlarına risk skorları sağlar. Ürün, analistlerin en yüksek riskli merchant'lara odaklanmasını ve yanlış pozitiflerin azaltılmasını hedefler [1]. Mastercard Merchant Risk Predict ise gelecekteki merchant fraud olasılığına ilişkin yedi tahmin skoru üretir ve bu skorların acquirer'ın kendi merchant risk modellemesine beslenmesini önerir [2]. Bu nedenle ChargeShield'in yenilik iddiası “merchant risk skoru ilk kez yapılıyor” olamaz.

Visa Merchant Screening Service, onboarding öncesinde yüksek riskli veya daha önce belirli nedenlerle sonlandırılmış merchant'ları değerlendirmek için acquirer'lara destek verir; Visa, transaction laundering, identity theft ve unfunded chargebacks gibi risklerin acquirer açısından finansal zarara dönüşebileceğini açıkça belirtir [3]. VMSS reason code'larında excessive chargebacks/refunds, fraud activity ve bankruptcy/insolvency gibi merchant-kaynaklı riskler bulunur. Bu, projenin birden fazla merchant risk mekanizmasını aynı ekonomik hedef altında ele almasını destekler.

4. Türkiye bağlamı ve düzenleyici doğrulama

TCMB'nin ödeme sistemleri mevzuat sayfasında 1 Kasım 2023 tarihli “Dolandırıcılık Eylemlerine İlişkin Talimat” güncel talimatlar arasında listelenmektedir [4]. TCMB 2023 Faaliyet Raporu da söz konusu talimatın tüketici mağduriyetlerinin önlenmesi, ödemeler alanının güvenliği ve ödeme/e-para kuruluşlarının itibarının korunması amacıyla yayımlandığını açıklar [5]. Bu, proje probleminin Türkiye ödeme ekosisteminde gerçek bir gözetim ve risk yönetimi bağlamına sahip olduğunu doğrular.

Bu çalışma, TCMB veya kart şemalarının belirlediği eşikleri yeniden üretme iddiasında değildir. PoC'de kullanılacak tüm eşikler “simulation threshold” olarak işaretlenecek; üretim sisteminde bankanın risk iştahı ve politika seti belirleyici olacaktır.

5. Zamansal modelleme, delayed labels ve leakage

Fraud Detection Handbook, terminal ve müşteri geçmişinden 1, 7 ve 30 günlük zaman pencereleri üretir; ayrıca fraud etiketlerinin müşteri şikâyeti veya soruşturma sonrasında gecikmeli kesinleşmesini modellemek için pencereleri geriye kaydırır [6]. Bu yaklaşım ChargeShield için doğrudan aktarılabilir: score_date sonrasında gerçekleşen chargeback/recovery sonuçları geçmiş feature'lara sızdırılmamalıdır.

Dolayısıyla random train/test split ana doğrulama yöntemi olmayacaktır. Train-validation-test dönemleri kronolojik kurulacak; 30 günlük prediction horizon ve etiket olgunlaşması için gerekli temporal gap/embargo tasarlanacaktır.

6. Müşteri geri bildirimi ve işletme bozulması

Naumzik, Feuerriegel ve Weinmann (2022), 921 restoranın 64.887 çevrimiçi puanını kullanarak işletme başarısızlığını zaman içindeki müşteri puan dizilerinden tahmin eder ve statik ortalamaya kıyasla zamansal örüntünün daha bilgilendirici olabileceğini gösterir [7]. Bu çalışma sanal POS chargeback zararını doğrudan kanıtlamaz; ancak “müşteri sesindeki değişim erken uyarı olabilir” hipotezi için güçlü yöntemsel emsaldır.

ChargeShield'de bu fikir, merchant-gün düzeyinde complaint_count, complaint_velocity, delivery_failure_share, refund_problem_share ve merchant_unreachable_share gibi özelliklere çevrilir. Şikâyet tek başına yaptırım üretmez; banka-içi davranış ve exposure verisiyle birlikte değerlendirilir.

7. eWOM, güven ve AI in Marketing ilişkisi

Ismagilova ve arkadaşlarının eWOM meta-analizi, mesaj kalitesi, valence, yararlılık ve güven gibi boyutların satın alma niyetiyle ilişkili olduğunu gösterir [8]. Bu literatür bankanın bilanço zararını tahmin etmez; fakat çözülmemiş merchant mağduriyetlerinin müşteri güveni ve ilişki yönetimi açısından neden önemli olduğunu açıklar.

Bu nedenle pazarlama katkısı fraud skorunun kendisi değil, bankanın merchant portföyünü riskle düzeltilmiş biçimde yönetmesi; yanlış pozitifleri azaltması, sağlıklı merchant retention'ı koruması ve analist kapasitesini daha değerli vakalara yönlendirmesidir.

8. Araştırma boşluğu ve proje katkısı

Savunulabilir araştırma boşluğu

Kamuya açık kaynaklarda merchant $\times$ day seviyesinde transaction + settlement/recovery + complaint sinyallerini birleştirip doğrudan gelecekteki tahsil edilemeyen acquirer zararını hedefleyen yeniden üretilebilir bir benchmark veri seti bulunmaması. ChargeShield bu açığı gerçek banka datası iddiasıyla değil, açık veri/simülatörlerle kalibre edilen bir Merchant Loss Simulator ve açıkça tanımlanmış ablation deneyleriyle PoC seviyesinde ele alır.

Literatür sonucu: Ana model merchant-level tabular risk tahmini olmalı; complaint NLP yardımcı sinyal olarak eklenmeli; temporal doğrulama ve delayed-label disiplini zorunlu tutulmalı; başarı accuracy yerine analist bütçesi ve ekonomik yakalama metrikleriyle ölçülmelidir.

BÖLÜM II Veri Araştırması

1. Veri amacı, gözlem birimi ve tahmin hedefi

Gözlem birimi: merchant × day. **Feature cutoff:** score_date sonu. **Prediction window:** takip eden 30 gün.

İki hedef değişken

1) risk_next_30d: takip eden 30 günde ciddi merchant adverse event oluştu mu? 2) net_unrecoverable_loss_30d: kesinleşmiş yükümlülüğün merchant recovery, reserve, held settlement ve diğer teminatlarla geri alınan kısmın düşülmesiyle kalan PoC ekonomik exposure.

2. İdeal banka/PSP veri şeması

Entity	Kritik alanlar	Neden gerekli?
merchant	merchant_id, onboarding_date, MCC, segment, expected_volume, settlement_policy, status	Kimlik, segmentasyon ve baseline
transaction	timestamp, amount, auth_result, decline_reason, 3DS, card/device/IP tokenları	Hacim, hız, konsantrasyon ve anomaliler
settlement	gross, held_amount, reserve_amount, released_amount	Bankanın elde tuttuğu / serbest bıraktığı fon
payout_balance	opening/closing balance, settlement_in, payout_out	Merchant'ın recovery kapasitesi ve para çıkışı
refund	request/completed date, amount, status, reason	Hizmet ve müşteri zararı sinyali
dispute_chargeback	opened_date, reason, amount, result, recovered_amount	Adverse event ve recovery ground truth
complaint	timestamp, channel, text, topic, confidence	Müşteri sesi ve erken sinyal
merchant_event	event_type, event_date, termination_reason, net_loss	Doğrulanmış adverse event / label

Modelin ham PAN, açık müşteri adı veya doğrudan kişisel kimlik bilgisine ihtiyacı yoktur. Kart/device/IP ilişkileri gerekli olduğunda stable token/pseudonymous identifier kullanılabilir.


3. Kullanılabilecek açık / vekil veri kaynakları

Kaynak	Tür	Kapsam / erişim	Merchant-level?	Gerçek net loss?	Projede rolü
Fraud Detection Handbook	Sentetik, açık	5.000 müşteri, 10.000 terminal, 183 gün, 1.754.155 işlem [6]	Terminal proxy	Hayır	Merchant simulator çekirdeği; 1/7/30d feature mantığı

Kaynak	Tür	Kapsam / erişim	Merchant-level?	Gerçek net loss?	Projede rolü
CardSim (Federal Reserve)	Sentetik simulator	Bayesian, modüler; kamu verileriyle kalibre edilebilir [9]	Uyarlanabilir	Hayır	Synthetic-to-real gap için metodolojik referans
IEEE-CIS Fraud Detection	Anonim e-commerce competition data	Transaction-level fraud etiketi; merchant id yok [10]	Hayır	Hayır	Tabular fraud feature benchmark; ana dataset değil
CFPB Complaint Database	Kamu, günlük güncellenen şikâyet verisi	CSV/JSON/API; narrative, company, issue, response [11]	Company-level proxy	Hayır	Complaint NLP pipeline ve bias analizi
Yelp / izinli review verisi	Third-party / lisanslı	Business-level review ve tarihsel sinyaller; kullanım hakkı plana bağlı [12]	Evet, business proxy	Hayır	Business feedback zaman serisi için yardımcı
Gerçek banka/PSP historical data	Private first-party	Merchant + settlement + dispute + recovery + complaint	Evet	Evet, üretilebilir	Gerçek dünya validasyonu - ideal hedef

Karar: PoC'yi yalnız IEEE-CIS gibi transaction-fraud datasına kurmak doğru değildir. Açık kaynaklar davranış ve feature tasarımını kalibre eder; settlement, reserve, recovery ve merchant deterioration mantığı için kendi Merchant Loss Simulator'ımız gerekir.

4. Merchant Loss Simulator tasarımı



Amaç: alarmı olumsuz olay ve net zarar tamamen gerçekleşmeden önce üretmek

Simülâtör, “fraud = bankanın otomatik zararı” varsayımını kullanmayacaktır. Önce adverse event / chargeback liability oluşur; ardından merchant balance, reserve, held settlement ve diğer recovery kanalları uygulanır; yalnız kalan kısım net unrecoverable loss olarak etiketlenir.

Senaryo	Bozulma sırasında beklenen sinyaller	Ekonomik sonuç
Hizmet sunamama / teslimat krizi	complaint ↑, delivery_failure ↑, refund request ↑, chargeback gecikmeli ↑	recovery açığı oluşabilir
Refund krizi	refund request ↑, refund completion ↓, refund complaint ↑	dispute ve müşteri zararı

Senaryo	Bozulma sırasında beklenen sinyaller	Ekonomik sonuç
Finansal distress	payout/outflow ↑, balance ↓, refund/dispute ↑	recovery kapasitesi düşer
Bust-out	volume ↑ ↑, payout ↑ ↑, merchant balance hızla düşer	gecikmeli chargeback bankada kalabilir
Sahte / collusive işlem	round amount, kart/device konsantrasyonu, olağandışı saat/hacim	fraud dispute + recovery açığı
Card testing / laundering	low-value auth/decline artışı veya MCC/faaliyet sapması	fraud/compliance exposure

5. Feature engineering

- 1/7/30 günlük işlem sayısı ve tutarı; average/median/p95 tutar; decline oranı; 3DS/non-3DS dağılımı.
- Merchant'ın kendi tarihsel baseline'ına göre yüzde değişim, z-score veya robust deviation özellikleri.
- Refund/dispute oranı, chargeback açılış hızı, recovered_amount oranı ve reserve coverage.
- Payout hızlanması, closing balance düşüşü, held/released settlement oranları.
- Complaint count, complaint velocity, risk-topic share, source confidence ve duplicate oranı.
- days_to_release: riskin kaynağı değil; müdahalenin aciliyetini belirleyen ayrı bir özellik.

6. EDA ve deneysel veri planı

- Sağlıklı vs. deteriorating merchant'larda olaydan önceki 60 günlük satış, refund, dispute, payout ve complaint trendlerini karşılaştırmak.
- Complaint velocity'nin refund/chargeback artışından önce yükselip yükselmediğini lead-lag analiziyle incelemek.
- Ham şikâyet sayısını merchant işlem hacmine göre normalize etmek; sektör ve merchant büyüklüğünü kontrol etmek.
- Transaction-only, +settlement/recovery ve +complaint feature setlerini ablation ile karşılaştırmak.
- Sentetik grafiklerde her rakamı açıkça "simulation / illustrative" olarak işaretlemek; gerçek banka bulgusu gibi sunmamak.

7. Veri kalitesi, gizlilik ve sınırlamalar

- Class imbalance: riskli merchant'lar azınlıktadır; accuracy yanıltıcı olabilir.
- Delayed labels: chargeback ve recovery sonucu haftalar sonra kesinleşebilir; strict feature cutoff gerekir.
- Entity resolution: dış şikâyetin yanlış merchant'a bağlanması ciddi false positive yaratır; confidence threshold gerekir.
- Complaint bias/manipulation: self-selection, sahte yorum, duplicate ve rakip kaynaklı gürültü kontrol edilmelidir.
- Privacy: şikâyet metninde isim, telefon, sipariş no veya ödeme bilgisi bulunabilir; minimization, maskeleye ve tokenization uygulanmalıdır.
- Synthetic-to-real gap: simülatör gerçek bankacılık dağılımının kanıtı değildir; gerçek banka datası gelirse parametreler yeniden kalibre edilmelidir.


Veri araştırması sonucu: PoC için veri stratejisi uygulanabilir; fakat başarının bilimsel koşulu sentetik veriyi "gerçek sonuç" gibi sunmamak ve her veri kaynağının hangi alt problemi test ettiğini açık biçimde ayırmaktır.

BÖLÜM III Teknoloji İncelemesi

1. Teknoloji seçiminin amacı

Amaç “en iyi LLM hangisi?” sorusunu yanıtlamak değil; dengesiz, zamansal ve çoğunlukla tabular bir merchant-risk probleminde açıklanabilir, düşük gecikmeli, denetlenebilir ve bankanın analist iş akışına entegre edilebilir bir AI yığını seçmektir.

2. Önerilen sistem mimarisi



İnsan analist incelemesi • otomatik POS kapatma yok

Ana model banka-içi yapılandırılmış veriden risk olasılığı üretir. NLP ve anomali modülleri yardımcı feature/score üretir. Fusion ağırlıkları elle uydurulmaz; validation setinde kalibre edilmiş meta-model veya stacking yaklaşımıyla öğrenilir.

3. Model karşılaştırması

Model	Rol	Artı	Eksi	Açıklanabilirlik	PoC kararı
Logistic Regression	Baseline / calibration	Basit, hızlı, şeffaf	Doğrusal etkileşim sınırı	Yüksek	Mutlaka benchmark
CatBoost	Ana classifier adayı	Kategorik özellik desteği, ordered boosting [13]	Tuning ve model karmaşıklığı	SHAP ile iyi	İlk tercih
LightGBM	Ana classifier adayı	Hızlı, histogram tabanlı, büyük tabular veride verimli [14]	Küçük datada overfit riski	SHAP ile iyi	Mutlaka karşılaştı
XGBoost	Ek benchmark	Güçlü standart GBDT	Benzer model ailesi; ek efor	SHAP ile iyi	Opsiyonel

Model	RoI	Artı	Eksi	Açıklanabilirlik	PoC kararı
Isolation Forest	Yardımcı anomali	Label dışı sıra dışılığı yakalayabilir	Risk ≠ anomali; tek başına zayıf olabilir	Orta	Sadece ek score
LLM classifier	Complaint NLP / özet	Türkçe parafraz ve yapılandırılmış çıkarım	Maliyet, halüsinasyon, drift	Kanıt gösterimi şart	Ana karar verici değil

4. Complaint NLP yaklaşımı

- Baseline: TF-IDF + Logistic Regression / Linear SVM ile çoklu risk-konu sınıflandırması.
- İkinci seviye: Türkçe/multilingual sentence embedding + küçük classifier; Türkçe parafrazları daha iyi yakalamak için.
- LLM: etiket bootstrapping, düşük güvenli örneklerin insan incelemesine yönlendirilmesi ve kanıta dayalı kısa analist özeti.
- Önerilen sınıflar: hizmet verilmedi, iade yapılmadı, merchant ulaşamıyor, müşteri oyalanıyor, yetkisiz ödeme, kalite şikâyeti, chargeback başladı.
- LLM hiçbir zaman “firma dolandırıcıdır” diye nihai yaptırım kararı vermez.

5. Değerlendirme tasarımı ve metrikler

Class imbalance nedeniyle accuracy ana metrik olmayacaktır. Değerlendirme, bankanın sınırlı analist kapasitesini ve ekonomik sonucu doğrudan yansıtan metriklere dayanacaktır:

- PR-AUC - nadir pozitif sınıfta genel sıralama kalitesi.
- Precision@K - günlük incelenebilen ilk K merchant içinde gerçekten riskli oran.
- Recall@AlertBudget - sabit alarm kapasitesinde yakalanan risk olaylarının payı.
- Detection Lead Time - ilk güvenilir alarm ile olumsuz olay arasındaki süre.
- Potentially Preventable / Captured Loss - alarm bütçesi altında yakalanan ekonomik exposure.
- Calibration / Brier - 0.80 risk skorunun gerçekten yaklaşık %80 olay olasılığına karşılık gelip gelmediği.
- False-positive Merchant Rate - sağlıklı işyerlerinin gereksiz inceleme/kısıt görme riski.

Deney / Ablation	Soru
E1 Logistic vs CatBoost vs LightGBM	Karmaşık model baseline'ı gerçekten geçiyor mu?
E2 Raw vs 1/7/30d rolling	Zamansal geçmiş değer katıyor mu?
E3 Rolling vs change-from-baseline	Merchant'ın kendi normalinden sapma ana hipotezi destekleniyor mu?
E4 Transaction-only vs +settlement/recovery	Finansal exposure katmanı ek değer sağlıyor mu?
E5 +Complaint NLP	Müşteri sesi lead time veya recall'ı artırıyor mu?
E6 +Anomaly/rules	Yeni veya etiketsiz örüntülerde yardımcı sinyal var mı?
E7 No-intervention vs risk policy	Simulator üzerinde preventable loss ne kadar değişiyor?

6. Açıklanabilirlik, insan gözetimi ve operasyon

SHAP, karmaşık modellerde tekil tahminlere feature katkısı atamak için kullanılabilir [15]. ChargeShield çıktısı yalnız 0-100 skor değil, analistin anlayabileceği reason-code ve kanıt seti olacaktır.

Örnek analist alarmı

Merchant M_01822 • Risk: 91/100 • Horizon: 30 gün • complaints +540% • refund ratio 3.0x • payout/outflow olağandışı • reserve coverage düşük • Öneri: MANUAL REVIEW + SETTLEMENT/RESERVE POLICY REVIEW. Otomatik termination yok.

Mastercard Merchant Monitoring'in analistlerin en yüksek riskli merchant'lara odaklanması, tekrarlayan işaretlemelerde manuel inceleme/soruşturma seçeneği ve risk eşliğini kârlılık/iş yüküne göre ayarlama yaklaşımı, human-in-the-loop tasarımının sektörel olarak gerçekçi olduğunu gösterir [1].

7. Deployment ve pratik değer

- PoC: günlük batch scoring + dashboard. Gerçek zamanlı API ilk faz için zorunlu değildir.
- Feature store: merchant-gün aggregation; model registry ve versioning; feature cutoff testleri.
- Monitoring: drift, calibration, source availability, complaint entity-matching confidence.
- Business value: daha yüksek loss captured, daha uzun lead time, daha düşük false positive ve daha iyi analist verimliliği.
- AI in Marketing value: sağlıklı merchant retention ve risk-adjusted merchant relationship management.

Teknoloji sonucu: İlk PoC için Logistic Regression baseline + CatBoost/LightGBM ana model + complaint NLP + yardımcı anomaly/rule signals + SHAP + human analyst queue en dengeli mimaridir. Derin sequence/graph modelleri ancak gerçek ve yeterince büyük veriyle ikinci fazda değerlendirilmelidir.

SONUÇ Tek Cümlede ChargeShield**Final proje cümlesi**

ChargeShield; bankanın sanal POS müşterilerini merchant × day seviyesinde kendi geçmiş davranışlarına göre izleyerek, işlem, settlement/recovery ve müşteri şikâyeti sinyallerinden önümüzdeki 30 gün içindeki ciddi merchant riski ve tahsil edilemeyen zarar olasılığını açıklanabilir biçimde tahmin eden bir erken uyarı PoC'sidir.

Bu problem neden seçildi? Çünkü aynı anda gerçek bir acquiring risk ihtiyacına, ölçülebilir bir ML problemine, açıklanabilir karar desteğine ve AI in Marketing kapsamında bankanın B2B merchant lifecycle/relationship management hedeflerine bağlanabilmektedir.

İlk senaryo: merchant müşterilerden ödeme almaya devam ederken hizmet sunamaz, refund/şikâyetler artar, sonrasında chargeback oluşur ve recovery yetersiz kalır. Sistem bu senaryoyu erken yakalamaya çalışır; ancak aynı mimari finansal distress, bust-out ve diğer merchant risk örüntülerini de kapsayabilir.

Başarı tanımı: “yüksek accuracy” değil; bankanın inceleme kapasitesi altında daha fazla gerçek risk olayını daha erken ve daha az sağlıklı merchant'ı rahatsız ederek yakalamaktır.

KAYNAKÇA Birincil ve Akademik Kaynaklar

[1] **Merchant Monitoring with AI.** Mastercard, erişim 15 Ağustos 2026.

<https://www.mastercard.com/global/en/business/cybersecurity-fraud-prevention/risk-decisioning/merchant-monitoring-with-ai.html>

[2] **Merchant Risk Predict.** Mastercard, erişim 15 Ağustos 2026.

<https://www.mastercard.com/global/en/business/cybersecurity-fraud-prevention/risk-decisioning/merchant-risk-predict.html>

[3] **Visa Merchant Screening Service**. Visa Developer, erişim 15 Ağustos 2026.

<https://developer.visa.com/capabilities/visa-merchant-screening-service>

[4] **Ödeme Sistemleri ile İlgili Mevzuat - 1.11.2023 tarihli Dolandırıcılık Eylemlerine İlişkin Talimat**. Türkiye Cumhuriyet Merkez Bankası.

<https://www.tcmb.gov.tr/wps/wcm/connect/TR/TCMB+TR/Main+Menu/Banka+Hakkinda/Mevzuat/Odeme+Sistemleri>

[5] **2023 Faaliyet Raporu - Finansal Altyapı**. Türkiye Cumhuriyet Merkez Bankası.

<https://www3.tcmb.gov.tr/yillikrapor/2023/m-2-5/>

[6] **Reproducible Machine Learning for Credit Card Fraud Detection - Practical Handbook**. Le Borgne, Y.-A. ve diğerleri.

<https://fraud-detection-handbook.github.io/fraud-detection-handbook/>

[7] **I Will Survive: Predicting Business Failures from Customer Ratings**. Naumzik, C.; Feuerriegel, S.; Weinmann, M.

Marketing Science, 41(1), 188-207, 2022. <https://doi.org/10.1287/mksc.2021.1317>

[8] **The Effect of Electronic Word of Mouth Communications on Intention to Buy: A Meta-Analysis**. Ismagilova, E. ve diğerleri.

Information Systems Frontiers, 22, 1203-1226, 2020. <https://doi.org/10.1007/s10796-019-09924-y>

[9] **CardSim: A Bayesian Simulator for Payment Card Fraud Detection Research**. Allen, J. S. Federal Reserve FEDS 2025-

017. <https://doi.org/10.17016/FEDS.2025.017>

[10] **IEEE-CIS Fraud Detection**. IEEE Computational Intelligence Society / Kaggle.

<https://www.kaggle.com/competitions/ieee-fraud-detection>

[11] **Consumer Complaint Database**. Consumer Financial Protection Bureau. <https://www.consumerfinance.gov/data-research/consumer-complaints/>

[12] **Yelp Data Licensing / Social Analytics**. Yelp. <https://business.yelp.com/data/solutions/social-analytics/>

[13] **CatBoost: Unbiased Boosting with Categorical Features**. Prokhorenkova, L. ve diğerleri. NeurIPS 2018.

<https://catboost.ai/docs/en/concepts/educational-materials-papers>

[14] **LightGBM: A Highly Efficient Gradient Boosting Decision Tree**. Ke, G. ve diğerleri. NeurIPS 2017.

<https://lightgbm.readthedocs.io/en/latest/Features.html>

[15] **A Unified Approach to Interpreting Model Predictions**. Lundberg, S. M.; Lee, S.-I. NeurIPS 2017.

<https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>