

ChargeShield

Veri Hazırlama ve Özellik Mühendisliği Raporu

Sanal POS kullanan işyerlerinde bloke süresi dolmadan chargeback riskini gösteren sinyallerin analizi

1. Veri Hazırlama ve Özellik Mühendisliği – Genel Bakış

ChargeShield’ın amacı, müşterinin ürün veya hizmeti alamadığı ve işyerinin müşteriyi bloke süresi boyunca oyaladığı senaryolarda bankaya erken inceleme sinyali vermektir. Bu çalışma eğitim amaçlı bir prototiptir. Olist verisi müşteri değerlendirmelerinden şikâyet benzeri sinyaller üretmek için, merchant/banka tablosu ise bankadan gelebilecek alanları göstermek üzere sentetik olarak kullanılmıştır.

Veri hazırlama; ham kayıtları merchant ve tarih düzeyinde birleştirir, eksik ve hatalı değerleri yönetir, ardından modelin kullanabileceği sayısal özellikleri üretir.

2. Veri Toplama

Kaynak	Kullanım	Sınırlama
Olist order reviews + orders + order items	order_id üzerinden yorumları seller_id ile eşleştirerek merchant-gün şikâyet sinyali üretme	Gerçek Şikâyetvar verisi değildir; gerçek firma adı ve chargeback etiketi içermez.
chargeshield_merchant_risk_synthetic.csv	İşlem, iade, chargeback, bloke/hakediş ve risk etiketi alanlarını prototipte göstermek	Tamamen sentetik; gerçek banka sonucu değildir.

Olist tarafında yalnızca merchant_id, complaint_date, complaint_title, complaint_text, customer_rating ve source alanları kullanılmıştır. Müşteri adı, adres, kart bilgisi ve gereksiz alanlar kullanılmamıştır.

3. Veri Temizleme

Kontrol	Uygulama
Kimlik ve tarih	merchant_id temizlendi; müşteri şikâyet tarihi ve banka observation_date alanları datetime’a çevrildi.
Eksik metin	Boş başlık/metinler boş değer olarak tutuldu; kayıt silinmedi.
Sayısal alanlar	Sayısalı çevrilemeyen değerler NaN yapıldı ve özellik üretiminden önce 0 ile dolduruldu.
Oranlar	Sonsuz değerler NaN’a çevrilip 0 yapıldı.
Aykırı değerler	Kayıtlar keyfi silinmedi. Gerçek veri geldiğinde alan bazlı aykırı değer politikası uygulanmalıdır.
Etiket	risk_label ikili 0/1 olarak kontrol edildi.

Birleşik tablo 65.599 merchant-gün satırı ve 47 sütundan oluşur; 3.076 anonim merchant içerir.

4. Keşifsel Veri Analizi (EDA)

EDA kapsamında veri tipleri, eksik değerler, risk etiketi dağılımı, şikâyet yoğunluğu, işlem/iade/chargeback oranları ve bloke süresi alanları incelenmiştir. 0 etiketi 56.074, 1 etiketi 9.525 satırdır; bu nedenle sınıf dengesizliği vardır. Olist yorumları gerçek chargeback olayları değildir ve bulgular gerçek dünyaya genellenebilir performans olarak sunulamaz.

İncelenen sinyal	Amaç
complaint_count ve complaint_rate_per_transaction	Şikâyet yoğunluğunu ve işlem hacmine göre normalize edilmiş şikâyeti görmek.
negative_review_ratio_7d/14d/30d	Memnuniyetsizlik sinyallerini farklı geçmiş pencerelerinde izlemek.
refund/chargeback oranları	İade ve chargeback davranışını işlem hacmiyle karşılaştırmak.
days_to_release	Bloke/hakediş zamanını risk sinyali olarak izlemek; etkisi gerçek veriyle doğrulanmalıdır.

5. Özellik Mühendisliği

Özellik	Gerekçe
complaint_count	Merchant-gün içindeki şikâyet yoğunluğu.
average_customer_rating	Günlük ortalama müşteri puanı.
negative_review_ratio	Düşük puanlı yorumların oranı.
late_delivery_review_ratio	Geç teslimatla ilişkili yorumların oranı.
complaint_rate_per_transaction	Şikâyeti işlem hacmine göre normalize eder.
refund_rate / chargeback_rate	İade veya chargeback sayısının işlem sayısına oranı.
refund_amount_ratio / chargeback_amount_ratio	İade/chargeback tutarının işlem hacmine oranı.
reserve_coverage	Bloke/rezerv tutarının işlem tutarına oranı.
days_to_release	Hakediş/bloke süresinde kalan gün bilgisi.

6. Veri Dönüşümü

Model aşamasına henüz geçilmediği için standardizasyon, encoding veya train-test dönüşümü uygulanmamıştır. Bu aşamada yalnızca tarih ve sayısal alan türleri düzenlenmiş, oran özellikleri hesaplanmış, gözlem tarihi ile release_date ayrıştırılmış ve veri modeli sonraki aşamaya hazır hale getirilmiştir.

7. Model Seçimi

İki model aynı veri ve kronolojik test bölümü üzerinde karşılaştırılmıştır. Logistic Regression, ikili risk tahmini için açıklanabilir ve izlenebilir bir temel modeldir. Ürettiği risk olasılığı ve katsayılar, bankaya hangi şikâyet veya işlem sinyalinin skoru etkilediğini açıklamayı kolaylaştırır. İkinci model olarak kullanılan Random Forest-style randomized decision-stump ensemble, doğrusal olmayan ilişkileri görmek amacıyla karşılaştırma modeli olarak eklenmiştir. merchant_id kimlik alanı ve release_date gelecekteki bilgiyi taşıdığı için model girdisine alınmamıştır.

8. Model Eğitimi

Veri observation_date sırasına göre %80 eğitim ve %20 test olarak ayrılmıştır. Eğitim: 52,479; test: 13,120. Sayısal özellikler eğitim bölümünün ortalama ve standart sapmasıyla standardize edilmiş, sınıf dengesizliği için eğitim ağırlıkları kullanılmıştır. Bu sonuçlar sentetik prototip etiketiyle üretilmiştir.


9. Model Değerlendirmesi

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.843	0.225	0.037	0.063	0.561
Random Forest-style ensemble	0.856	0.000	0.000	0.000	0.570

Sonuçlar güçlü değildir; bu, modelin gerçek riskli merchantları ayırt etme gücünün şu an sınırlı olduğunu gösterir. Random Forest-style model ROC-AUC bakımından Logistic Regression'dan yalnızca 0,009 daha yüksektir (0,570'e karşı 0,561). Bu küçük fark tek başına anlamlı bir üstünlük kanıtı değildir. Daha önemlisi, 0,5 eşik değerinde Random Forest-style modelin recall değeri 0,000 olmuş ve 1.886 riskli kaydın hiçbirini yakalayamamıştır. Logistic Regression 69 riskli kaydı yakalamış, ancak recall değeri yine düşük kalmıştır (0,037).

Bu nedenle mevcut prototip sonuçlarına göre üretim için doğrudan Random Forest-style model seçilmemelidir. ChargeShield'ın temel amacı riskli merchantları kaçırmamak olduğu için Logistic Regression şu aşamada daha uygun temel adaydır: daha açıklanabilir ve mevcut eşikte en azından bazı riskli kayıtları yakalamaktadır. Bununla birlikte Logistic Regression da yeterli değildir; eşik değeri düşürülmeli, recall-precision dengesi incelenmeli ve gerçek banka verisiyle yeniden eğitilmelidir. Random Forest-style model ise daha yüksek ROC-AUC potansiyeli nedeniyle eşik optimizasyonu ve daha güçlü ağaç yapısıyla tekrar test edilebilir. Kesin model seçimi gerçek chargeback etiketleri ve bankanın kabul edebileceği yanlış alarm maliyetiyle yapılmalıdır.

ChargeShield — Model ROC-AUC Karşılaştırması



Şekil: ROC-AUC karşılaştırması. Grafik sentetik prototip sonuçlarına aittir.

Bu metrikler sentetik etiketli prototip verisinden elde edilmiştir; gerçek bankacılık performansı değildir. Özellikle yüksek sonuçlar, sentetik etiket üretim kuralının modele kolayca öğrenilebilir olmasıyla açıklanabilir. Gerçek/anonim banka chargeback sonuçlarıyla yeniden doğrulama yapılmadan üretim kararı verilmemelidir.

10. Kod Uygulaması ve Çıktılar

01_data_preparation_feature_engineering.py iki veri setini okur, temizler, merchant-gün düzeyinde birleştirir ve ana CSV'yi üretir. 02_model_exploration.py bu ana dosyayı okuyarak model eğitimi ve değerlendirme çıktıları üretir. Yeni veriler geldiğinde önce veri hazırlama, ardından model kodu aynı sırayla çalıştırılabilir.

Ana çıktı: chargeshield_prepared_merchant_day.csv. Bu dosya yeni bir gerçek veri kaynağı değildir; iki mevcut veri setinin model öncesi birleşik ve özelleştirilmiş halidir.

11. Sonuç ve Sonraki Aşama

Karşılaştırma sonucunda Random Forest-style model ROC-AUC’de küçük bir farkla önde olsa da riskli kayıtları yakalayamamıştır. Bu nedenle mevcut eşikte Logistic Regression daha uygun temel modeldir; açıklanabilir olması ve en azından bazı riskli kayıtları yakalaması bankanın inceleme süreci için daha değerlidir. Ancak iki modelin de recall değeri düşük olduğu için henüz gerçek kullanıma hazır değildir. Sonraki aşamada eşik optimizasyonu yapılmalı, farklı eşiklerde recall–precision dengesi ölçülmeli ve gerçek banka chargeback etiketleriyle model yeniden doğrulanmalıdır. Sentetik veri sonuçları yalnızca yöntem gösterimi olarak değerlendirilmelidir.